



Data Architecture — InvestMap Maroc



Data Architecture — InvestMap Maroc

Version: 1.0 | **Date:** Mai 2026 | **Statut:** Reference Document

Lié au PRD: PRD v4.0 — InvestMap Maroc

1. Vue d'ensemble — Les 3 types de données

Type	Agent	Sources	Disponibilité Demo	Disponibilité Production
Données locales	Agent 1 + 2	Google Maps · HCP · Google Trends	✅ 100% réel	✅ 100% réel
Données de défaillance	Agent 5	Google Maps Closed · Inforisk	⚠️ Synthetic calibré	✅ Maps + RC partnership
Données Radar	Agent 6 + 7	AMDIE · CRI · Presse économique	⚠️ 20 projets hardcoded	✅ Scraping automatique 24h

2. 🌍 Données Locales — Agent 1 + Agent 2

2.1 Google Maps Places API

Rôle : Cartographier tous les commerces existants dans un rayon donné

Coût : Gratuit jusqu'à 200\$/mois — amplement suffisant pour le hackathon

Appel API :

```
GET https://maps.googleapis.com/maps/api/place/nearbysearch/json
?location=34.8612,-2.3317 // Berkane centre
&radius=1200 // 1.2km
&type=pharmacy // type de commerce
&key=API_KEY
```

Réponse brute :

```
{
  "results": [
    {
      "name": "Pharmacie Al Amal",
      "geometry": { "location": { "lat": 34.862, "lng": -2.331 } },
      "business_status": "OPERATIONAL",
      "rating": 4.2,
      "user_ratings_total": 47
    }
  ]
}
```

Ce qu'on extrait :

```
def analyze_competition(lat, lng, business_type, radius=1200):
    results = google_maps.nearby_search(
        location=(lat, lng),
        radius=radius,
        type=business_type
    )
    operational = [r for r in results if r.status == 'OPERATIONAL']
    closed = [r for r in results if r.status == 'CLOSED_PERMANENTLY']

    return {
        'competitors_count': len(operational),
        'historical_closures': len(closed),
        'commercial_gap': len(operational) == 0
    }
```

Types de commerces utilisés :

Type Google Maps	Business dans notre app
pharmacy	Pharmacie
restaurant	Restaurant
clothing_store	Magasin vêtements
convenience_store	Épicerie
car_wash	Lavage auto
copy_center	Centre photocopie

Type Google Maps	Business dans notre app
supermarket	Supermarché

2.2 HCP — Haut Commissariat au Plan

Rôle : Données démographiques et économiques par commune

Source : hcp.ma → RGPH 2024 → Données par commune

Coût : Gratuit — données publiques officielles

Structure de notre base HCP locale :

```
{
  "commune": "Berkane",
  "region": "Oriental",
  "population": 120000,
  "avg_income_monthly_dh": 4800,
  "unemployment_rate": 0.123,
  "youth_population_pct": 0.31,
  "literacy_rate": 0.76,
  "households_count": 28500,
  "urban_pct": 0.82
}
```

Comment on l'utilise dans le scoring :

```
def income_score_factor(avg_income):
    if avg_income > 6000: return +15 # Riche
    if avg_income > 4000: return +10 # Moyen+
    if avg_income > 2500: return +5  # Moyen
    return 0                       # Faible
```

Stratégie de collecte :

- Télécharger les fichiers Excel HCP pour les 5 villes pilotes
- Parser et insérer en base PostgreSQL manuellement
- Mise à jour annuelle (données stables)

2.3 Google Trends API

Rôle : Mesurer le volume de recherche local pour chaque type de business

Coût : Gratuit

Librairie Python : `pytrends`

```

from pytrends.request import TrendReq

def get_local_demand(keyword, city_code='MA-05'):
    pytrends = TrendReq(hl='fr-MA')
    pytrends.build_payload(
        [keyword],
        geo=city_code,      # MA-05 = Oriental
        timeframe='today 12-m'
    )
    data = pytrends.interest_over_time()
    return {
        'monthly_avg': data[keyword].mean(),
        'trend': 'rising' if data[keyword].iloc[-3:].mean() > data[
keyword].mean() else 'stable',
        'peak_months': get_peak_months(data[keyword])
    }

```

Codes régions Maroc pour Trends :

Ville	Code Google Trends
Berkane / Oujda	MA-05 (Oriental)
Marrakech	MA-07
Tanger	MA-01
Casablanca	MA-06
Agadir	MA-09

2.4 Google Maps Reviews – NLP

Rôle : Détecter la demande non satisfaite dans les avis clients

Mots-clés recherchés :

```

DEMAND_SIGNALS = [
    'trop loin', 'ما فيش قريب', 'عيد',
    'introuvable', 'manque', 'besoin de',
    'ليتني كان', 'واش كاين'
]

def extract_demand_signals(reviews: list[str]) -> dict:
    signals = []
    for review in reviews:
        for keyword in DEMAND_SIGNALS:

```

```

        if keyword.lower() in review.lower():
            signals.append({'review': review, 'signal': keyword})
    d})
    return {
        'demand_signals_count': len(signals),
        'demand_level': 'high' if len(signals) > 5 else 'medium' if len(signals) > 2 else 'low'
    }

```

3. Données de Défaillance — Agent 5

3.1 Le défi

Inforisk et le Registre du Commerce ne fournissent pas d'API gratuite pour les données historiques de faillite. C'est le point de données le plus complexe du projet.

Stratégie en 2 couches :

Couche	Source	Disponibilité	Qualité
Couche 1	Google Maps Permanently Closed	✓ Gratuit maintenant	★★★★★ Très bonne
Couche 2	Synthetic data sur base Inforisk	✓ Gratuit maintenant	★★★★ Bonne
Couche 3 (V2)	Registre du Commerce partnership	💰 Payant	★★★★★★★★ Parfaite

3.2 Couche 1 — Google Maps Permanently Closed

Pourquoi c'est puissant : Google Maps marque les commerces fermés avec `business_status: CLOSED_PERMANENTLY`. Ce sont des données de défaillance réelles et gratuites.

```

def get_historical_closures(lat, lng, business_type, radius=1500):
    """
    Récupère le nombre de fermetures historiques
    d'un type de commerce dans un rayon donné
    """
    all_places = google_maps.nearby_search(
        location=(lat, lng),
        radius=radius,
        type=business_type,
        include_closed=True # paramètre important
    )

    closures = [
        p for p in all_places
        if p['business_status'] == 'CLOSED_PERMANENTLY'
    ]

```

```

]

return {
    'closures_count': len(closures),
    'closure_names': [p['name'] for p in closures],
    'failure_signal': len(closures) >= 3 # Signal fort
}

```

Impact sur le score Agent 5 :

```

closures = get_historical_closures(lat, lng, 'clothing_store')
# closures = {'closures_count': 3, 'failure_signal': True}

score -= closures['closures_count'] * 8
# score -= 3 * 8 = -24 points
# Message: "3 magasins de vêtements ont fermé ici (2021-2024)"

```

3.3 Couche 2 — Synthetic Data (Taux Inforisk)

Source : Inforisk publie des rapports annuels avec les taux de défaillance par secteur — gratuitement.

Notre table de taux de défaillance calibrée :

```

# Basé sur Inforisk Baromètre 2023/2024
# Source: rapport public officiel

FAILURE_RATES_BY_SECTOR = {
    # (taux_3ans, taux_5ans)
    'clothing_store': (0.23, 0.41), # 23% ferment en 3 ans
    'restaurant': (0.31, 0.52),
    'cafe': (0.28, 0.47),
    'pharmacy': (0.08, 0.15), # Très stable
    'copy_center': (0.12, 0.22),
    'car_wash': (0.18, 0.33),
    'grocery': (0.15, 0.27),
    'bakery': (0.19, 0.35),
    'electronics': (0.26, 0.44),
    'beauty_salon': (0.21, 0.38),
}

def get_sector_risk(business_type: str) -> dict:
    rates = FAILURE_RATES_BY_SECTOR.get(business_type, (0.20, 0.3

```

```

5))
    risk_level = 'low' if rates[0] < 0.15 else 'medium' if rates
[0] < 0.25 else 'high'
    return {
        'failure_rate_3y': rates[0],
        'failure_rate_5y': rates[1],
        'risk_level': risk_level
    }

```

Réponse au jury si questionnés :

"Nos taux de défaillance sont calibrés sur les statistiques officielles publiées par Inforisk dans leur Baromètre 2023/2024, complétées par les fermetures réelles détectées via Google Maps 'Permanently Closed'. En production, nous passerons à un partenariat avec les CRI régionaux pour accéder aux données du Registre du Commerce."

4. 📡 Données Radar — Agent 6 + Agent 7

4.1 Pipeline de collecte




Table: investment_projects

4.2 Agent 6 — Data Collector (Scraping)

```
import asyncio
from bs4 import BeautifulSoup
from playwright.async_api import async_playwright

SOURCES = [
    {
        'name': 'AMDIE',
        'url': 'https://www.investinmorocco.com/fr/projets',
        'type': 'static',          # BeautifulSoup
        'selector': '.project-card'
    },
    {
        'name': 'Medias24',
        'url': 'https://medias24.com/economie/',
        'type': 'dynamic',        # Playwright (JavaScript)
        'selector': '.article-item'
    },
    {
        'name': 'CRI Oriental',
        'url': 'https://www.cri-oriental.ma/projets',
        'type': 'static',
        'selector': '.investment-row'
    }
]

async def collect_from_source(source: dict) -> list[str]:
    if source['type'] == 'static':
        response = requests.get(source['url'])
        soup = BeautifulSoup(response.text, 'html.parser')
        elements = soup.select(source['selector'])
        return [el.get_text(strip=True) for el in elements]

    elif source['type'] == 'dynamic':
        async with async_playwright() as p:
            browser = await p.chromium.launch()
            page = await browser.new_page()
            await page.goto(source['url'])
```

```

        await page.wait_for_selector(source['selector'])
        elements = await page.query_selector_all(source['selector'])

        texts = [await el.inner_text() for el in elements]
        await browser.close()
        return texts

async def run_collection():
    all_texts = []
    for source in SOURCES:
        texts = await collect_from_source(source)
        all_texts.extend(texts)
        print(f"Collected {len(texts)} items from {source['name']}")
    return all_texts

```

4.3 Agent 7 — Project Analyzer (LLM Extraction)

Rôle : Transformer le texte brut en JSON structuré via Claude API

```

import anthropic

client = anthropic.Anthropic(api_key=API_KEY)

EXTRACTION_PROMPT = """
Tu es un expert en analyse d'investissements au Maroc.
Analyse le texte suivant et extrait les informations d'investissement.
Réponds UNIQUEMENT avec un objet JSON valide, sans texte autour.
Si une information est absente, mets null.

Texte à analyser:
{text}

Format JSON attendu:
{{
    "nom_projet": string,
    "secteur": "agriculture|energie|tourisme|industrie|infrastructure|immobilier|tech|autre",
    "region": "Tanger-Tétouan|Oriental|Fès-Meknès|Rabat-Salé|Béni Mellal|Casablanca|Marrakech|Drâa-Tafilalet|Souss-Massa|Guelmim|Laâyoune|Dakhla",

```

```

    "montant_mad": number_or_null,
    "promoteur": string,
    "phase": "planifié|en_cours|complété",
    "date_lancement": string_or_null,
    "emplois_crees": number_or_null,
    "is_investment": boolean
}}
"""

def extract_project(raw_text: str) -> dict | None:
    response = client.messages.create(
        model='claude-sonnet-4-6',
        max_tokens=500,
        messages=[{
            'role': 'user',
            'content': EXTRACTION_PROMPT.format(text=raw_text)
        }]
    )

    try:
        result = json.loads(response.content[0].text)
        if not result.get('is_investment'):
            return None # Pas un projet d'investissement
        return result
    except json.JSONDecodeError:
        return None # LLM n'a pas retourné du JSON valide

```

Exemple complet d'extraction :

```

raw_text = """
OCF Group a annoncé hier lors d'une conférence de presse
à Casablanca un investissement de 3 milliards de dirhams
pour la construction d'une nouvelle unité de production
à Jorf Lasfar, province d'El Jadida. Le projet, prévu
pour 2027, créera 2000 emplois directs.
"""

result = extract_project(raw_text)
# Output:
# {
#   'nom_projet': 'Unité OCF Jorf Lasfar',
#   'secteur': 'industrie',
#   'region': 'Casablanca-Settat',

```

```
# 'montant_mad': 3000000000,
# 'promoteur': 'OCP Group',
# 'phase': 'planifié',
# 'date_lancement': '2027',
# 'emplois_crees': 2000,
# 'is_investment': True
# }
```

4.4 Les 20 projets hardcodés — Demo Miathon

Pour la démo, ces projets sont directement insérés en base. Tous sont des projets réels.

```
HARDCODED_PROJECTS = [
    {
        "id": 1,
        "nom": "Nador West Med Phase 2",
        "secteur": "infrastructure",
        "region": "Oriental",
        "montant_mad": 10_000_000_000,
        "promoteur": "Agence Nador West Med",
        "phase": "en_cours",
        "progress_pct": 65,
        "emplois": 15000,
        "lat": 35.17, "lng": -2.93,
        "source": "medias24.com"
    },
    {
        "id": 2,
        "nom": "Parc Éolien Taza",
        "secteur": "energie",
        "region": "Fès-Meknès",
        "montant_mad": 800_000_000,
        "promoteur": "NAREVA Holding",
        "phase": "planifié",
        "progress_pct": 20,
        "emplois": 800,
        "lat": 34.21, "lng": -4.01,
        "source": "leconomiste.com"
    },
    {
        "id": 3,
        "nom": "Zone Industrielle Berkane Extension",
```

```

    "secteur": "industrie",
    "region": "Oriental",
    "montant_mad": 350_000_000,
    "promoteur": "CRI Oriental",
    "phase": "complété",
    "progress_pct": 100,
    "emplois": 3500,
    "lat": 34.92, "lng": -2.34,
    "source": "cri-oriental.ma"
  },
  # ... 17 autres projets réels
]

```

Sources pour compléter les 20 projets :

- investinmorocco.com/fr/projets
- leconomiste.com (recherche "investissement 2025")
- medias24.com (recherche "milliards dirhams")
- mmsp.gov.ma (contrats d'investissement signés)

5. Schéma Base de Données

```

-- Communes (données HCP)
CREATE TABLE communes (
  id          SERIAL PRIMARY KEY,
  nom         VARCHAR(100) NOT NULL,
  region      VARCHAR(100),
  population  INTEGER,
  avg_income_dh INTEGER,
  unemployment DECIMAL(5,4),
  youth_pct   DECIMAL(5,4),
  lat         DECIMAL(9,6),
  lng         DECIMAL(9,6),
  geom        GEOMETRY(POINT, 4326)
);

-- Analyse locale (cache des appels Google Maps)
CREATE TABLE local_analysis (
  id          SERIAL PRIMARY KEY,
  commune_id  INTEGER REFERENCES communes(id),
  neighborhood VARCHAR(100),

```

```

business_type    VARCHAR(50),
competitors      INTEGER DEFAULT 0,
closures         INTEGER DEFAULT 0,
demand_score     INTEGER DEFAULT 0,
analyzed_at      TIMESTAMP DEFAULT NOW(),
lat              DECIMAL(9,6),
lng              DECIMAL(9,6)
);

```

```
-- Projets d'investissement (Radar)
```

```

CREATE TABLE investment_projects (
  id          SERIAL PRIMARY KEY,
  nom         VARCHAR(255) NOT NULL,
  secteur     VARCHAR(50),
  region      VARCHAR(100),
  montant_mad BIGINT,
  promoteur   VARCHAR(200),
  phase       VARCHAR(20),
  progress_pct INTEGER DEFAULT 0,
  emplois     INTEGER,
  lat         DECIMAL(9,6),
  lng         DECIMAL(9,6),
  geom        GEOMETRY(POINT, 4326),
  source_url   TEXT,
  collected_at TIMESTAMP DEFAULT NOW(),
  is_hardcoded BOOLEAN DEFAULT FALSE
);

```

```
-- Rapports générés (cache)
```

```

CREATE TABLE investment_reports (
  id          SERIAL PRIMARY KEY,
  user_profile VARCHAR(50),
  commune     VARCHAR(100),
  neighborhood VARCHAR(100),
  budget      INTEGER,
  top_business VARCHAR(100),
  success_score INTEGER,
  report_json  JSONB,
  created_at   TIMESTAMP DEFAULT NOW()
);

```

```
-- Index géographiques pour PostGIS
```

```
CREATE INDEX idx_communes_geom ON communes USING GIST(geom);
```

```
CREATE INDEX idx_projects_geom ON investment_projects USING GIST(geom);
```

6. Connexion Radar → Invest (Le boost)

Comment un grand projet améliore le score local :

```
RADAR_BOOST_BUSINESSES = {
    # Pour chaque type de grand projet,
    # quels business locaux sont boostés ?
    'infrastructure': {
        'gas_station': +20,
        'restaurant': +15,
        'warehouse': +18,
        'hotel': +12,
        'construction': +25
    },
    'tourisme': {
        'restaurant': +20,
        'souvenir_shop': +22,
        'transport': +18,
        'hotel': +25,
        'pharmacy': +10
    },
    'industrie': {
        'restaurant': +18,
        'housing': +20,
        'supermarket': +15,
        'pharmacy': +12
    },
    'energie': {
        'construction': +20,
        'logistics': +15
    }
}

def get_radar_boost(lat, lng, business_type, radius_km=80):
    """
    Cherche les grands projets dans un rayon de 80km
    et calcule le boost sur le score de succès
    """
    nearby = db.query("""
```

```

        SELECT nom, secteur, montant_mad, phase,
               ST_Distance(geom, ST_MakePoint(%s,%s)::geography)/1
000 as distance_km
        FROM investment_projects
        WHERE ST_DWithin(
            geom,
            ST_MakePoint(%s,%s)::geography,
            80000 -- 80km en mètres
        )
        AND phase IN ('en_cours', 'planifié')
        ORDER BY distance_km ASC
        """', (lng, lat, lng, lat))

total_boost = 0
boost_reasons = []

for project in nearby:
    sector_boosts = RADAR_BOOST_BUSINESSES.get(project.secteu
r, {})
    boost = sector_boosts.get(business_type, 0)

    # Réduire le boost si le projet est loin
    distance_factor = max(0, 1 - (project.distance_km / 80))
    adjusted_boost = int(boost * distance_factor)

    if adjusted_boost > 0:
        total_boost += adjusted_boost
        boost_reasons.append({
            'project': project.nom,
            'distance_km': project.distance_km,
            'boost': adjusted_boost
        })

    return {
        'total_boost': min(total_boost, 25), # Cap à +25 pts
        'reasons': boost_reasons
    }

```

Exemple pour le scénario Hassan :

```

boost = get_radar_boost(34.86, -2.33, 'gas_station')
# Output:
# {

```

```
# 'total_boost': 20,
# 'reasons': [
#   {
#     'project': 'Nador West Med Phase 2',
#     'distance_km': 61.3,
#     'boost': 20
#   }
# ]
# }
```

Score final:
base 50 + concurrence +25 + demande +15 + revenu +10
- fermetures -8 + radar_boost +20 = 112 → capped à 100 ✓
Mais pour pharmacie: 50+25+15+10-8+0 = 92 → pas de boost
Pour station-service: 50+20+12+8-0+20 = 110 → 94/100 ✓

7. 📋 Stratégie Data pour le Hackathon

Priorité absolue — Ce qui doit fonctionner à 100%

H0 → H4: Préparer les données Berkane

- ✓ Insérer communes Berkane + Oujda en **base** (données HCP)
- ✓ Tester Google Maps **API** → récupérer concurrents Berkane
- ✓ Insérer les **20** projets hardcodés
- ✓ Tester Google Trends pour "**pharmacie berkane**"

Données hardcodées pour la démo — Berkane, Al Massira

```
# À préparer AVANT le hackathon
BERKANE_MASSIRA_DATA = {
  'commune': 'Berkane',
  'neighborhood': 'Al Massira',
  'lat': 34.8612, 'lng': -2.3317,
  'population_1km': 12400,
  'avg_income': 4800,
  'businesses': {
    'pharmacy': {
      'operational': 0,           # 0 concurrent
      'closed': 1,              # 1 fermeture
      'demand_monthly': 340     # Google Trends
    }
  },
}
```

```

        'clothing_store': {
            'operational': 3,
            'closed': 3,
            'demand_monthly': 120
        },
        'cafe': {
            'operational': 4,
            'closed': 2,
            'demand_monthly': 200
        },
        'copy_center': {
            'operational': 0,
            'closed': 0,
            'demand_monthly': 180
        }
    }
}

```

3 fermetures ← signal for

Réponse préparée pour le jury

Q: D'où viennent vos données ?

R: "Trois sources : (1) Google Maps Places API pour les commerces existants et fermés — gratuit et en temps réel. (2) HCP open data pour les données démographiques par commune — données officielles. (3) Google Trends pour la demande de recherche locale. Pour le Radar : 20 projets réels hardcodés depuis AMDIE et la presse économique, avec un pipeline de scraping automatique prévu pour la V2."

Q: Vos données de défaillance sont-elles fiables ?

R: "Oui — deux couches : Google Maps 'Permanently Closed' pour les fermetures réelles dans chaque quartier, et les taux sectoriels Inforisk publiés officiellement pour calibrer le modèle. En production, nous aurons un partenariat CRI pour les données RC."

8. Librairies et dépendances

```

# requirements.txt

# Google Maps
googlemaps==4.10.0

# Google Trends
pytrends==4.9.2

```

```
# Scraping
requests==2.31.0
beautifulsoup4==4.12.2
playwright==1.40.0

# NLP simple
re # stdlib

# Database
psycpg2-binary==2.9.9
sqlalchemy==2.0.23
geoalchemy2==0.14.3 # PostGIS

# AI
anthropicai==0.34.0 # Claude API
langchain==0.1.0

# Utils
apscheduler==3.10.4 # Collecte automatique 24h
pandas==2.1.4
```

Document de référence — InvestMap Maroc · ENIAD Berkane · Miathon 2026